

UNIVERSIDADE SÃO JUDAS TADEU

EDUARDO HENRIQUE NOGUEIRA SALMAN

GUSTAVO MARQUES

JOÃO VICTOR VIEIRA DIAS

PABLO MALDONADO ROCHA

RAFAELLA ISALTO

YASMIM PEREIRA DA COSTA

AVALIAÇÃO A3

COMITÊ DE CLASSIFICADORES

SÃO PAULO

2026

EDUARDO HENRIQUE NOGUEIRA SALMAN
GUSTAVO MARQUES
JOÃO VICTOR VIEIRA DIAS
PABLO MALDONADO ROCHA
RAFAELLA ISALTO
YASMIM PEREIRA DA COSTA

AVALIAÇÃO A3
COMITÊ DE CLASSIFICADORES

PROJETO APRESENTADO AO
CURSO DE ENGENHARIA DE
SOFTWARE COMO REQUISITO
PARA OBTENÇÃO DE NOTA.

ORIENTADOR: PROF. RODRIGO
BOSSINI

SÃO PAULO

2026

SUMÁRIO

INTRODUÇÃO.....	4
DESCRIÇÃO DA BASE DE DADOS.....	5
DEFINIÇÃO DO PROBLEMA.....	6
PRÉ-PROCESSAMENTO.....	7
MODELAGEM.....	8
CONSTRUÇÃO DO COMITÊ.....	9
RESULTADOS E MÉTRICAS.....	10
DISCUSSÃO.....	11
CONCLUSÃO.....	12

INTRODUÇÃO

Avaliar a qualidade de um vinho é uma tarefa historicamente atribuída a especialistas, seguido por um processo caro, demorado e sujeito a variações subjetivas. Com a disponibilidade crescente de dados sobre a composição química dos vinhos, surge a possibilidade de desenvolver modelos capazes de estimar essa qualidade de forma mais objetiva e escalável.

Este projeto tem como objetivo construir modelos que consigam prever a nota de qualidade de amostras de vinhos, variando de 3 a 8, a partir de um conjunto de atributos químicos como acidez, teor alcoólico, pH e sulfatos. O dataset utilizado é o *Wine Quality* (WineQT), disponível publicamente na plataforma Kaggle.

O trabalho analisa o desenvolvimento por completo, desde o tratamento dos dados até a avaliação dos modelos, classificados por cinco algoritmos distintos — KNN, Árvore de Decisão, Naive Bayes, SVM e Rede Neural — e seus resultados foram combinados em um comitê, estratégia que agrega as previsões de múltiplos modelos para chegar em uma decisão final mais precisa.

A principal finalidade é observar se a combinação de modelos escolhida apresenta vantagens em relação ao uso de cada algoritmo isoladamente, e o que os resultados concluem no que se refere o problema de classificação de qualidade de vinhos.

DESCRIÇÃO DA BASE DE DADOS

Para o desenvolvimento deste trabalho foi utilizada uma base de dados pública disponibilizada na plataforma Kaggle, contendo informações sobre diferentes amostras de vinhos. Essa base reúne características físico-químicas obtidas por meio de análises laboratoriais, permitindo relacionar esses atributos com a qualidade final do produto.

Cada registro da base representa uma amostra de vinho e é composto pelos seguintes atributos: acidez fixa, acidez volátil, ácido cítrico, açúcar residual, cloretos, dióxido de enxofre livre, dióxido de enxofre total, densidade, pH, sulfatos e teor alcoólico.

Além desses atributos, a base possui uma variável denominada qualidade, que representa a classificação atribuída ao vinho. Essa variável foi utilizada como alvo durante o treinamento dos modelos de Inteligência Artificial.

A escolha dessa base permitiu o desenvolvimento e a avaliação dos algoritmos em um conjunto de dados amplamente utilizado em estudos de aprendizado de máquina.

DEFINIÇÃO DO PROBLEMA

O projeto tem como objetivo desenvolver um sistema de Inteligência Artificial capaz de classificar a qualidade de vinhos a partir de suas características físico-químicas.

Esse problema é classificado como um problema de aprendizado supervisionado, no qual os algoritmos são treinados utilizando exemplos previamente rotulados. A partir desses exemplos, os modelos aprendem padrões existentes nos dados e passam a realizar previsões sobre novas amostras.

Além da construção do sistema, também foi realizada uma comparação entre diferentes algoritmos de classificação, com o objetivo de identificar qual deles apresenta melhor desempenho para esse conjunto de dados.

PRÉ-PROCESSAMENTO

Inicialmente, a base de dados foi importada para o ambiente Google Colab utilizando a linguagem Python. Em seguida, foi realizada a separação entre as variáveis de entrada (X), correspondentes às características dos vinhos, e a variável de saída (y), correspondente à sua qualidade.

Posteriormente, os dados passaram por uma etapa de padronização, de forma que todos os atributos permanecessem em uma mesma escala. Essa etapa é importante para evitar que variáveis com valores muito elevados tenham maior influência durante o treinamento de alguns algoritmos.

Após o pré-processamento, a base foi dividida em conjuntos de treinamento e teste. O conjunto de treinamento foi utilizado para o aprendizado dos modelos, enquanto o conjunto de teste foi utilizado para avaliar seu desempenho em dados que não participaram do treinamento.

MODELAGEM

Para a construção do sistema foram utilizados cinco algoritmos de classificação supervisionada: Naive Bayes (NB), Árvore de Decisão, K-Nearest Neighbors (KNN), Support Vector Machine (SVM) e Rede Neural Artificial.

Todos os modelos foram treinados utilizando a mesma base de dados e posteriormente avaliados por meio da métrica de acurácia, que representa a proporção de classificações realizadas corretamente.

Os resultados obtidos mostraram que a Rede Neural Artificial apresentou o melhor desempenho entre os classificadores individuais, alcançando uma acurácia de 66,88%. O algoritmo SVM obteve 64,19% de acerto. Por vez o sistema de Árvore de Decisão ficou em 62,45%. Seguindo nas últimas posições temos KNN com apenas 58,08% de assertividade e NB com seus 57,64%.

Além dos classificadores individuais, também foram implementadas duas técnicas de ensemble: Comitê Majoritário e Comitê Ponderado. Nesses métodos, a decisão final é obtida a partir da combinação das previsões realizadas pelos diferentes algoritmos.

Os dois métodos de comitê apresentaram os melhores resultados do trabalho, alcançando uma acurácia de 68,12% no método majoritário e 69,43% no método ponderado, demonstrando que a combinação de classificadores pode proporcionar um desempenho superior ao dos modelos individuais.

CONSTRUÇÃO DO COMITÊ

Após o treinamento e avaliação individual dos cinco modelos, foi construído o comitê de classificadores, também chamado de *ensemble*. A ideia central dessa abordagem

é combinar as previsões de diferentes modelos para chegar a uma decisão final com mais precisão do que a de qualquer modelo sozinho. Dessa forma, duas estratégias de combinação foram implementadas:

1. Votação Majoritária

Nessa estratégia, cada modelo "vota" na classe que previu para cada amostra, e a classe que receber mais votos é escolhida como a previsão final. Como são cinco modelos, não há possibilidade de empate. Essa é a abordagem mais simples e direta, tratando todos os modelos com o mesmo peso independentemente de seu desempenho individual.

2. Votação Ponderada

Nessa estratégia, os modelos com maior acurácia individual têm mais influência na decisão final. Os pesos foram calculados proporcionalmente à acurácia de cada modelo no conjunto de teste, normalizados para que a soma seja igual a 1. Desse modo, um modelo que acerta mais recebe mais peso na votação, tornando o comitê mais sensível ao desempenho de cada algoritmo.

As duas estratégias foram avaliadas utilizando as mesmas métricas dos modelos individuais — acurácia, precisão, recall, F1-score e matriz de confusão — permitindo uma comparação direta entre as abordagens e os classificadores isolados.

RESULTADOS E MÉTRICAS

Ao todo, foram avaliados sete modelos: cinco classificadores individuais e dois comitês. O conjunto de teste contou com 229 amostras, distribuídas entre as notas 3 e 8, com forte concentração nas notas 5 (97 amostras) e 6 (92 amostras), enquanto as notas extremas — 3 e 8 — tiveram apenas 1 e 3 amostras respectivamente.

Entre os modelos individuais, a Rede Neural obteve o melhor desempenho, com 66,81% de acurácia, seguida pelo SVM (64,19%), Árvore de Decisão (62,45%), KNN (58,08%) e Naive Bayes (57,64%).

Após a combinação dos modelos no comitê, os resultados melhoraram. A votação majoritária atingiu 68,12% de acurácia, e a votação ponderada chegou a 69,43% — o melhor resultado geral, superando inclusive o modelo individual mais forte.

Em relação às notas específicas, todos os modelos apresentaram boa performance nas notas 5 e 6, que são as mais representadas no dataset. Já as notas 3, 4 e 8 foram praticamente ignoradas pelos modelos, o que era esperado dado o número muito reduzido de amostras nessas categorias — um reflexo direto do desbalanceamento do dataset.

DISCUSSÃO

Os resultados obtidos mostram que a construção do comitê trouxe uma melhora significativa em comparação com os modelos individuais. O comitê por votação ponderada, com 69,43% de acurácia, foi o modelo com melhor desempenho geral,

confirmando que dar mais peso aos modelos mais precisos é uma estratégia mais eficiente do que tratar todos igualmente, como faz a votação majoritária.

Dito isso, observa-se uma limitação importante destacada no decorrer do projeto: o desbalanceamento do dataset. As notas 5 e 6 concentram a grande maioria das amostras, o que faz com que os modelos aprendam muito bem a identificar vinhos com essas notas, mas tenham dificuldade com as notas extremas. As notas 3 e 8, por exemplo, tiveram precisão e recall zerados em praticamente todos os modelos, ou seja, nenhum classificador conseguiu identificá-las corretamente. Isso não é necessariamente uma falha dos algoritmos, mas sim uma consequência direta da falta de exemplos suficientes para que os modelos aprendam esses padrões.

Outro ponto a ser levantado é que a Rede Neural apresentou um aviso de convergência durante o treinamento, indicando que o modelo não completou seu processo de otimização dentro do número máximo de iterações definido. Ainda assim, foi o melhor modelo individual, o que sugere que com mais iterações poderia ter resultados ainda melhores.

Por fim, vale destacar que a acurácia geral dos modelos, entre 57% e 69%, seja um resultado razoável para um problema de classificação com 6 classes e dataset desbalanceado. Problemas assim são naturalmente mais difíceis comparados a classificações binárias, e os resultados refletem essa complexidade.

CONCLUSÃO

Este trabalho teve como objetivo desenvolver um pipeline completo de classificação supervisionada aplicado ao dataset *Wine Quality*, desde o pré-processamento dos dados até a construção e avaliação de um comitê de classificadores.

Os cinco modelos treinados individualmente apresentaram desempenhos variados, com a Rede Neural liderando com 66,81% de acurácia. A combinação desses modelos no comitê demonstrou ser uma abordagem vantajosa: a votação ponderada alcançou 69,43% de acurácia, superando todos os classificadores individuais e confirmando que a integração de múltiplos modelos pode produzir resultados mais robustos do que qualquer um deles isoladamente.

O principal desafio encontrado foi o desbalanceamento do dataset, que prejudicou a capacidade dos modelos de identificar vinhos com notas extremas, como 3 e 8. Em trabalhos futuros, técnicas como o balanceamento artificial de classes poderiam ser aplicadas para contornar esse problema e melhorar o desempenho nessas categorias.

De forma geral, o projeto atingiu seus objetivos: foi possível aplicar na prática os conceitos de aprendizado supervisionado estudados em aula, comparar diferentes algoritmos de classificação e demonstrar o valor do uso de comitês como estratégia para melhorar a qualidade das predições.